

Лекция: Двумерная дискретная случайная величина

“Совместная работа должна включать страстные разногласия.”
Harvard Business Review, “Collective Genius”

Определение

Двумерная случайная величина — это пара случайных величин (X, Y) , определённых на одном и том же вероятностном пространстве.

Каждое наблюдение представляет собой упорядоченную пару значений (x_i, y_j) .

Совместное (совместное) распределение вероятностей

Совместное распределение (joint distribution) — это распределение вероятностей двух случайных величин X и Y , которое показывает вероятности всех возможных сочетаний их значений.

$$P(X = x_i, Y = y_j)$$

Пример: «Оценки и удовлетворённость учёбой»

Маша предполагает, что существует связь между успешностью в учёбе и удовлетворённостью учебным процессом.

Она собрала данные о двух переменных:

- G — оценка студента по пробному экзамену по математике, $G = \{2, 3, 4, 5\}$;
- S — уровень удовлетворённости учёбой в ВИШ, где:
 - $S = 0$ — «совсем не удовлетворён»,
 - $S = 1$ — «в целом доволен»,
 - $S = 2$ — «полностью доволен».

Результаты представлены в виде таблицы совместного распределения:

G / S	$S=0$	$S=1$	$S=2$
$G=2$	1/16	1/12	5/48
$G=3$	1/16	1/8	1/16
$G=4$	1/16	1/8	1/16
$G=5$	1/16	1/12	5/48

Каждая ячейка — это вероятность пересечения соответствующих значений G и S .

Например:

$$P(G = 2 \cap S = 1) = \frac{1}{12}$$

Предельные распределения (Marginal Distributions)

Чтобы получить распределение **отдельной** случайной величины (например, только G или только S), нужно просуммировать вероятности по строкам или столбцам.

G / S	S=0	S=1	S=2	P(G)
G=2	1/16	1/12	5/48	1/4
G=3	1/16	1/8	1/16	1/4
G=4	1/16	1/8	1/16	1/4
G=5	1/16	1/12	5/48	1/4
P(S)	1/4	5/12	1/3	1

Проверка

Сумма всех вероятностей в таблице равна 1:

$$\sum_{i,j} P(G = g_i, S = s_j) = 1$$

Каждая строка показывает распределение вероятностей для заданного значения G, а каждый столбец — для заданного значения S.

S	0	1	2
P(S)	1/4	5/12	1/3

Математическое ожидание уровня удовлетворённости:

$$E(S) = 0 \cdot 1/4 + 1 \cdot 5/12 + 2 \cdot 1/3 = 17/12 \approx 1.42$$

Интерпретация:

Если случайно выбрать студента, можно ожидать, что его удовлетворённость будет чуть выше среднего уровня (около 1.4).

Условное распределение (Conditional Distribution)

Иногда нас интересует не общее распределение, а распределение одной случайной величины при фиксированном значении другой.

Например:

Если студент получил отличную оценку по математике (G=5), можно ли ожидать, что он будет более удовлетворён учёбой?

Чтобы ответить на этот вопрос, нужно рассчитать условное распределение и условное математическое ожидание.

Пример: «Оценки и удовлетворённость» при G = 5

Напомним часть таблицы совместного распределения:

G / S	S=0	S=1	S=2	P(G)
-------	-----	-----	-----	------

G=5	1/16	1/12	5/48	1/4
-----	------	------	------	-----

Условное распределение S при G=5

Чтобы найти $P(S = s | G = 5)$, используем формулу условной вероятности:

$$P(S = s | G = 5) = \frac{P(S = s \cap G = 5)}{P(G = 5)}$$

Поскольку $P(G = 5) = 1/4$, получаем:

$$P(S = 0 | G = 5) = \frac{1/16}{1/4} = \frac{1}{4},$$

$$P(S = 1 | G = 5) = \frac{1/12}{1/4} = \frac{1}{3},$$

$$P(S = 2 | G = 5) = \frac{5/48}{1/4} = \frac{5}{12}.$$

Условное распределение удовлетворённости при отличной оценке (G=5)

S	0	1	2
P(S G = 5)	1/4	1/3	5/12

Условное математическое ожидание

Математическое ожидание при заданном условии $G=5$ вычисляется аналогично, только используется условное распределение:

$$E[S | G = 5] = \sum_i s_i P(S = s_i | G = 5)$$

$$E[S | G = 5] = 0 \cdot 1/4 + 1 \cdot 1/3 + 2 \cdot 5/12 = 14/12 = 1.17$$

Интерпретация

- Без условий (из общей таблицы):

$$E(S) = 1.42$$

- При $G = 5$:

$$E(S|G = 5) = 1.17$$

Значит, при фиксированной оценке 5 уровень удовлетворённости **чуть ниже**, чем средний по выборке.

Если бы получилось наоборот (например, $1.6 > 1.4$), мы могли бы сказать, что студенты с высокими оценками **в целом более довольны** обучением.

Общая формула условного математического ожидания

$$E(X | Y = y_j) = \sum_{i=1}^n x_i P(X = x_i | Y = y_j)$$

Независимость случайных величин

Напомним: две случайные величины X и Y называются **независимыми**, если знание значения одной не влияет на распределение другой.

То есть:

$$P(X = x_i, Y = y_j) = P(X = x_i) \cdot P(Y = y_j)$$

В нашем примере G и S **не независимы**, так как $P(S | G)$ зависит от G : уровень удовлетворённости студентов изменяется в зависимости от их оценки.

Если случайные величины независимы, то их **совместное распределение** можно построить из **маргинальных** (отдельных) распределений:

X	y_1	y_2	$\dots$	y_m
x_1	$p_1 \cdot q_1$	$p_1 \cdot q_2$	$\dots$	$p_1 \cdot q_m$
x_2	$p_2 \cdot q_1$	$p_2 \cdot q_2$	$\dots$	$p_2 \cdot q_m$
$\dots$	$\dots$	$\dots$	$\dots$	$\dots$
x_k	$p_k \cdot q_1$	$p_k \cdot q_2$	$\dots$	$p_k \cdot q_m$

То есть, если известны отдельные распределения $P(X)$ и $P(Y)$ и известно, что X и Y независимы, то

$$P(X, Y) = P(X) \cdot P(Y)$$

для всех сочетаний значений.

 Без знания факта независимости **невозможно восстановить** совместное распределение по маргинальным.

Ковариация (Covariance)

В предыдущих разделах мы рассматривали **одномерные** случайные величины — их распределение, математическое ожидание, дисперсию и т.д.

Теперь возникает естественный вопрос:

Как связаны между собой две случайные величины?

Например:

- Связаны ли **государственные расходы** с **уровнем инфляции**?
- Зависит ли **успеваемость студента** от **времени, затраченного на учёбу**?
- Есть ли взаимосвязь между **оценками** и **уровнем удовлетворённости обучением**?

Интуитивная идея

Ковариация измеряет, насколько **одновременные изменения** двух случайных величин направлены в одну сторону или в противоположные.

- Если при увеличении X величина Y **тоже растёт** $\rightarrow$ ковариация **положительная**.
- Если при увеличении X величина Y **уменьшается** $\rightarrow$ ковариация **отрицательная**.
- Если зависимости нет $\rightarrow$ ковариация **близка к нулю**.

Определение

Ковариация определяется как математическое ожидание произведения отклонений случайных величин от их средних значений:

$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))]$$

или, раскрывая определение математического ожидания для дискретного случая:

$$\text{Cov}(X, Y) = \sum_i \sum_j (x_i - \mu_X)(y_j - \mu_Y) P(X = x_i, Y = y_j)$$

где

$$\mu_X = E(X), \mu_Y = E(Y).$$

Интерпретация

Значение $\text{Cov}(X, Y)$	Интерпретация
> 0	X и Y растут вместе (положительная связь)
< 0	X растёт, а Y уменьшается (обратная связь)
≈ 0	Нет линейной зависимости

Важное замечание

- Единицы измерения ковариации зависят от единиц измерения X и Y (например, «баллы $\times$ уровень удовлетворённости»).
- Чтобы устранить влияние масштабов, вводится **коэффициент корреляции (ρ)** — нормированная форма ковариации, лежащая в пределах $[-1; 1]$.

📌 **Ковариация может принимать любые значения:**

$$-\infty < \text{Cov}(X, Y) < \infty$$

Как интерпретировать $\text{Cov}(X, Y)$?

Ковариация — это математическое ожидание произведения отклонений двух случайных величин от их средних.

Рассмотрим ситуации:

✓ **Положительная связь**

Если между X и Y существует **прямая тенденция**, то есть:

- когда X выше среднего $\rightarrow Y$ тоже выше среднего,
- когда X ниже среднего $\rightarrow Y$ также ниже среднего,

то произведение

$$(X - \mu_X)(Y - \mu_Y)$$

обычно **положительно**, и их среднее будет больше нуля:

$$\text{Cov}(X, Y) > 0$$

✓ **Отрицательная связь**

Если X и Y движутся в противоположных направлениях:

- X выше среднего $\rightarrow Y$ ниже среднего,
- X ниже среднего $\rightarrow Y$ выше среднего,

то произведение отрицательно $\rightarrow$ ковариация:

$$\text{Cov}(X, Y) < 0$$

✓ **Отсутствие линейной связи**

Если величины не связаны линейно, положительные и отрицательные произведения компенсируют друг друга, и:

$$\text{Cov}(X, Y) \approx 0$$

 **Нулевая ковариация означает отсутствие линейной зависимости, но НЕ означает независимости.**

Две полезные формулы ковариации

Формула 1. Упрощённая формула

Иногда ковариацию удобнее вычислять так:

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$$

Доказательство

Начнём с определения:

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] =$$

Раскрываем скобки:

$$= E[XY - X\mu_Y - Y\mu_X + \mu_X\mu_Y] =$$

Так как μ_X и μ_Y — константы, вынесем их:

$$= E(XY) - \mu_Y E(X) - \mu_X E(Y) + \mu_X\mu_Y =$$

Но

$$E(X) = \mu_X,$$

$$E(Y) = \mu_Y,$$

поэтому:

$$= E(XY) - \mu_Y\mu_X - \mu_X\mu_Y + \mu_X\mu_Y =$$

$$= E(XY) - \mu_X\mu_Y$$

Что и требовалось доказать.

✅ Формула 2. Связь дисперсии суммы с ковариацией

В главе про дисперсию суммы случайных величин мы встречали формулу:

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$$

Доказательство

$$\begin{aligned}\text{Var}(X + Y) &= E[(X + Y - E(X + Y))^2] = E[(X - \mu_X + Y - \mu_Y)^2] = \\ &= E[(X - \mu_X)^2 + (Y - \mu_Y)^2 + 2(X - \mu_X)(Y - \mu_Y)] = \\ &= \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)\end{aligned}$$

Аналогично можно получить формулу:

$$\text{Var}(X - Y) = \text{Var}(X) + \text{Var}(Y) - 2\text{Cov}(X, Y)$$

Корреляция (Correlation)

Мы уже увидели, что **ковариация** отражает совместную динамику двух случайных величин — растут ли они вместе или движутся в противоположных направлениях.

Однако ковариация имеет важный недостаток:

Её значение зависит от единиц измерения, масштаба и разброса обеих переменных.

Поэтому ковариацию нельзя использовать для сравнения силы связи между разными парами переменных.

◆ Почему ковариация «масштабозависима»?

Рассмотрим два примера:

✓ Пример 1: госрасходы и ВВП

Ковариация между государственными расходами и ВВП **в большой стране** всегда будет выше, чем в маленькой.

Но это не означает, что связь сильнее — просто **сами величины измеряются в больших числах**.

✓ Пример 2: рост и вес человека

Пусть

- X — вес,
- Y — рост.

Если:

- вес измерен в **граммах**,
- рост — в **сантиметрах**,

то отклонения $(X - E(X))$ и $(Y - E(Y))$ будут большими $\rightarrow$ ковариация будет большой.

Если те же величины измерить в **килограммах** и **метрах**, числа станут меньше $\rightarrow$ ковариация уменьшится, хотя связь между ростом и весом **не изменилась**.

! Вывод

Ковариация **не отражает чистую силу связи** между переменными. Она отражает:

- масштаб,
- единицы измерения,
- разброс величин.

То есть сравнивать ковариацию между разными парами переменных нельзя.

Нам нужен нормированный показатель связи

То есть такая мера, которая:

- очищена от масштабов,
- не зависит от единиц измерения,
- не искажается величинами разброса,
- отражает только **силу линейной связи** между переменными.

Такой мерой является **корреляция**.

Коэффициент корреляции Пирсона

Возьмём формулу ковариации:

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

Заметим, что величины $(X - \mu_X)$ и $(Y - \mu_Y)$ зависят от:

- разброса X ,
- разброса Y ,
- размера чисел.

Чтобы убрать влияние масштаба, мы нормируем ковариацию на произведение стандартных отклонений:

$$\sigma_X = \sqrt{\text{Var}(X)}, \quad \sigma_Y = \sqrt{\text{Var}(Y)}$$

И получаем **коэффициент корреляции**:

$$\rho_{XY} = \text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

◆ Свойства корреляции

✓ Диапазон значений

$$-1 \leq \rho_{XY} \leq 1$$

✓ Интерпретация

Значение ρ	Толкование
+1	идеальная положительная линейная связь
0.7 – 1	сильная положительная
0.3 – 0.7	умеренная положительная
0 – 0.3	слабая положительная
0	нет линейной зависимости
-0.3 – 0	слабая отрицательная
-0.7 – -0.3	умеренная отрицательная
-1 – -0.7	сильная отрицательная
-1	идеальная отрицательная линейная связь

Почему корреляция лучше ковариации?

- корреляция не зависит от единиц измерения;
- нормирована: всегда в диапазоне от -1 до 1;
- позволяет сравнивать силу связи между разными парами переменных;
- отражает исключительно **силу** линейной зависимости, а не масштаб величин.

🔥 Корреляция ≠ Причинность

(Correlation does not imply causation)

Когда корреляция между двумя случайными величинами X и Y ненулевая, это может означать любое из трёх:

- X влияет на Y ;
- Y влияет на X ;
- обе величины зависят от третьей переменной W , которая и создаёт наблюдаемую связь.

📌 Пример: «Умные дети носят большие ботинки?!»

Если изучить связь между:

- размером обуви школьников
- результатами IQ-теста

можно получить **высокую положительную корреляцию**.

Но это же не значит, что «большие ноги делают детей умнее»!

Правильное объяснение:

- и IQ, и размер обуви растут **с возрастом**.

Возраст — это скрытая переменная (**confounder**), создающая ложную корреляцию.

Вывод

Корреляция **не означает**, что одна переменная вызывает другую.

Корреляция говорит только об одном:

X и Y — НЕ независимы. Между ними есть некоторая линейная связь.

Но она НЕ говорит:

- какой переменной вызвана другая;
- существует ли вообще причинная связь.

🔥 Независимость vs. Некоррелированность

Два ключевых понятия часто путают. Разберём точно и аккуратно.

✓ Определения

Независимость

$$X \text{ и } Y \text{ независимы} \Leftrightarrow P(X = x_i, Y = y_j) = P(X = x_i)P(Y = y_j) \quad \forall i, j$$

Некоррелированность

$$X \text{ и } Y \text{ некоррелированы} \Leftrightarrow \text{Cov}(X, Y) = 0 \Leftrightarrow E(XY) = E(X)E(Y)$$

✓ Главное свойство

$$\text{📌 Независимость} \Rightarrow \text{Некоррелированность}$$

Это всегда выполняется.

Доказательство (понятное и короткое)

Если X и Y независимы:

$$P(X = x_i, Y = y_j) = P(X = x_i)P(Y = y_j)$$

Тогда:

$$\begin{aligned} E(XY) &= \sum_{i,j} x_i y_j P(X = x_i, Y = y_j) \\ &= \sum_{i,j} x_i y_j P(X = x_i) P(Y = y_j) \\ &= \left(\sum_i x_i P(X = x_i) \right) \cdot \left(\sum_j y_j P(Y = y_j) \right) \\ &= E(X)E(Y) \end{aligned}$$

Следовательно:

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = 0$$

✓ Независимые переменные — всегда некоррелированные.

✗ Обратное НЕверно

Некоррелированность $\nRightarrow$ Независимость

То, что $\text{Cov}(X, Y) = 0$, НЕ означает, что переменные независимы.

Почему?

Потому что равенство:

$$E(XY) = E(X)E(Y)$$

может выполняться **случайно**, за счёт специфической формы распределения, даже если переменные имеют сложную, нелинейную зависимость.

📌 Классический пример

Возьми $X \sim U[-1, 1]$ и $Y = X^2$.

Тогда:

- X и Y явно зависимы (значение Y полностью определяется X !)
- но $\text{Cov}(X, Y) = 0$.

Таблица возможных комбинаций

	Независимы	Не независимы
Некоррелированы ($\rho = 0$)	✓ Возможно	✓ Возможно
Коррелированы ($\rho \neq 0$)	✗ Невозможно	✓ Возможно

Значит:

- Если корреляция $\neq 0 \rightarrow$ точно есть зависимость.
- Если корреляция $= 0 \rightarrow$ ничего нельзя сказать о независимости.

Пример из задачи «Оценки и удовлетворённость» (G и S)

1. Проверка независимости

Проверяем:

$$P(G = 3 \cap S = 1) = P(G = 3) \cdot P(S = 1)$$

Считаем:

$$P(G = 3, S = 1) = \frac{1}{8}$$

$$P(G = 3) = \frac{1}{4}, \quad P(S = 1) = \frac{5}{12}$$

$$P(G = 3)P(S = 1) = \frac{1}{4} \cdot \frac{5}{12} = \frac{5}{48} \neq \frac{1}{8}$$

👉 **G и S НЕ независимы.**

2. Проверка корреляции

Вычислим:

$$\begin{aligned} E(G) &= \frac{7}{2} \\ E(S) &= \frac{13}{12} \\ E(GS) &= \frac{91}{24} \end{aligned}$$

$$\text{Cov}(G, S) = E(GS) - E(G)E(S)$$

$$= \frac{91}{24} - \frac{7}{2} \cdot \frac{13}{12}$$

$$= \frac{91}{24} - \frac{91}{24} = 0$$

Следовательно:

$$\rho_{GS} = 0$$

👉 **G и S — некоррелированы,**

но НЕ независимы (мы доказали это выше).

🎯 Итоговые выводы

- **Корреляция ≠ причинность.**
Она НЕ говорит, что одно вызывает другое.
- **Независимость ⇒ некоррелированность, но некоррелированность НЕ ⇒ независимость.**
- Переменные G и S:
 - не независимы,
 - но некоррелированы.

Отличный учебный пример!